Detección de exoplanetas en curvas de luz de Kepler: features físicas versus redes convolucionales 1D

INF396 – Informe de avance

Noelia Morales Matías Lara
Ingeniería Civil Informática, Universidad Técnica Federico Santa María
Repositorio: `https://github.com/n0eli4/inf396-exoplanetas`

1. Problema y objetivo

Una curva de luz es la medición del brillo de una estrella a lo largo del tiempo, registrada por el telescopio espacial Kepler. Cuando un planeta pasa por delante de su estrella, bloquea una pequeña fracción de su luz y el brillo baja durante unas horas (un *tránsito*); como el planeta orbita, la caída se repite con regularidad. Es como observar un faro lejano: si cada cierto tiempo algo pasa por delante y lo apaga brevemente, deducimos que algo gira a su alrededor.

Detectar esa señal es difícil: la caída es diminuta, del orden de 0,01 % a 1 % del brillo, y comparable al ruido. Además, las estrellas varían su brillo por sí solas (manchas, rotación, erupciones) y el telescopio introduce errores de medición. A esto se suma que las estrellas con planeta confirmado son extremadamente escasas: 37 de 5.087 en el entrenamiento (0,73 %). Un modelo que prediga siempre "sin planeta" obtiene 99,27 % de *accuracy* sin detectar ninguno, por lo que esta métrica no sirve en este problema.

En la literatura, las redes convolucionales han mostrado ser efectivas para clasificar señales de tránsito en datos de Kepler [6, 1], y los clasificadores de *gradient boosting* sobre features extraídas de la curva alcanzan resultados comparables con un costo computacional mucho menor [3]. Sobre el mismo dataset que usamos, Priyadarshini y Puri [4] reportan 99,62 % de *accuracy* con un ensamble de CNN, cifra poco informativa dado que un clasificador trivial obtiene 99,12 % en el mismo conjunto de prueba.

Objetivo. Comparar un clasificador basado en features con significado físico contra una red neuronal convolucional 1D para detectar exoplanetas en curvas de luz de Kepler, con un protocolo de evaluación adecuado al fuerte desbalance de clases, y analizar mediante técnicas de interpretabilidad qué patrones aprende la red. En concreto: (1) baseline con features físicas (FFT y periodograma BLS) y modelos Random Forest y XGBoost; (2) CNN 1D sobre la curva preprocesada; (3) estudio de ablación; (4) interpretabilidad con mapas de saliencia y Grad-CAM 1D [5].

Ajustes respecto a la propuesta.

- *PR-AUC* es la métrica principal; el conjunto de prueba oficial (solo 5 positivos) se usa como confirmación y no para decidir.
- La CNN se evaluó con 5 folds × 1 repetición (el baseline con 5 × 5) por costo de cómputo.
- La CNN de esta etapa aún no usa *data augmentation* ni ajuste de hiperparámetros: se reporta como versión inicial.
- Se agregó al preprocesamiento un recorte de picos hacia arriba, que no figuraba en la propuesta (ver Sección 4).

2. Solución propuesta

La Figura 1 resume el enfoque: una misma curva preprocesada alimenta dos ramas que se comparan bajo el mismo protocolo de evaluación.

Rama A: features físicas. Se extraen 18 features por estrella: 8 estadísticos de la distribución del flujo (mínimo, percentiles 1 y 5, desviación, asimetría, curtosis, y conteo de puntos bajo -3σ y -5σ); 4 del espectro de Fourier (frecuencia y relevancia del pico dominante, fracción de potencia en bajas y altas frecuencias); y 6 del periodograma *Box Least Squares* (BLS) [2]. El BLS busca una caída rectangular repetida: para cada par (período, duración) pliega la curva y mide qué tan bien

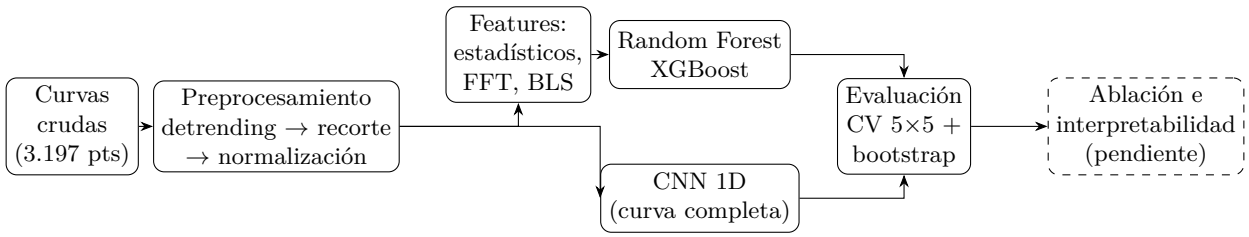


Figura 1: Esquema general de la solución. Las cajas punteadas están pendientes.

se alinean las caídas. Se exploran 3.000 períodos entre 0,5 y 30 días y 4 duraciones (0,05 a 0,3 días); de la mejor "caja" se toman período, duración, profundidad, SNR, contraste frente al periodograma típico y número de tránsitos que caben en la curva. Sobre estas features se entrenan Random Forest (300 árboles, `balanced_subsample`) y XGBoost (300 árboles, profundidad 3, `scale_pos_weight` = negativos/positivos del fold de entrenamiento).

Rama B: CNN 1D. Recibe la curva preprocesada (recortada a $[-30, 5]$) y aprende sus propios patrones: tres bloques Conv1D (16, 32 y 64 filtros, núcleos de 7, 5 y 5) con BatchNorm, ReLU y MaxPool, un *global max pooling* que responde "¿algún filtro encontró su patrón en alguna parte de la curva?", un *dropout* de 0,3 y una capa lineal. Se entrena con entropía cruzada ponderada (`pos_weight` = negativos/positivos), Adam (tasa 10^{-3}), 20 épocas fijas y lotes de 64. No se usa parada temprana: con unos 7 positivos por fold, un conjunto de validación interno sería demasiado ruidoso.

Evaluación. Validación cruzada estratificada de 5 folds repetida 5 veces sobre el entrenamiento (1 vez para la CNN), con recall, precisión, F1 y PR-AUC; intervalos de confianza al 95 % por *bootstrap* estratificado (1.000 remuestras) en el conjunto de prueba. Las features y el preprocesamiento se calculan estrella por estrella, por lo que no hay fuga de información entre folds.

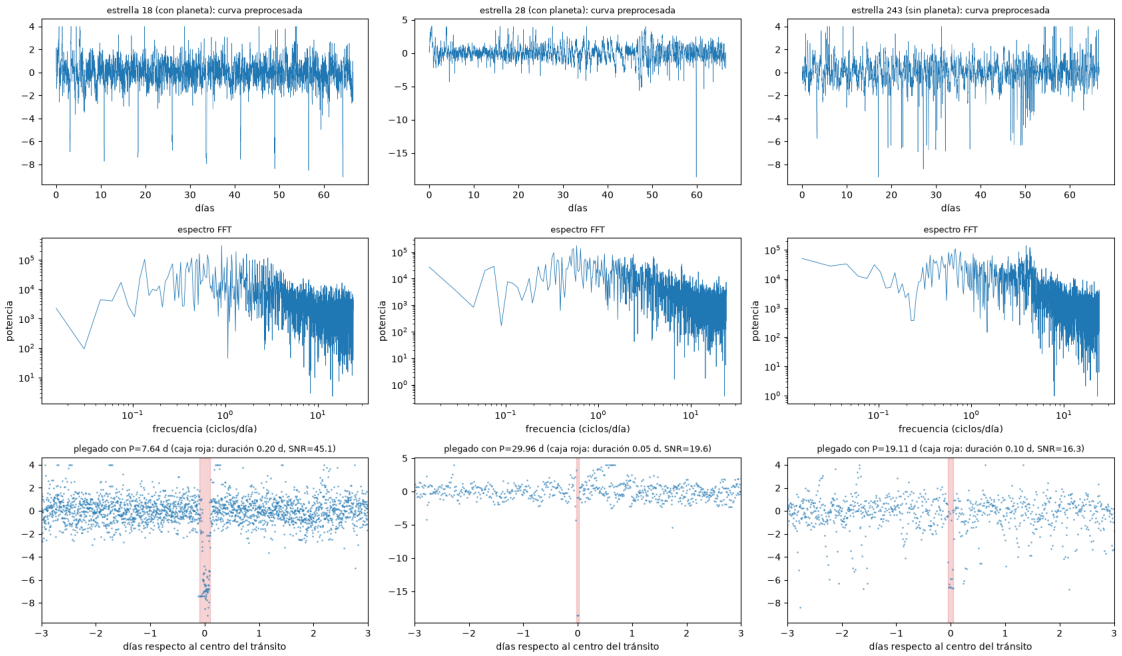


Figura 2: Curva preprocesada, espectro FFT y plegado BLS de tres estrellas. En la estrella 18 (con planeta) el plegado con $P = 7{,}64$ d apila caídas de unos -7σ (SNR 45); en la 28 (con planeta) el BLS se apoya en una sola caída profunda; en la 243 (sin planeta) las caídas no se alinean. La FFT no muestra un pico claro en ninguna.

3. Plan de implementación

El código está en un repositorio de GitHub con lógica reutilizable en `src/` y notebooks que solo la invocan.

Componente	Estado	Archivo / detalle
Carga y exploración de datos	Hecho	`src/data.py`, `01_exploracion`
Preprocesamiento	Hecho	`src/preprocessing.py`, `02_preprocesamiento`
Protocolo de evaluación	Hecho	`src/evaluation.py`: CV repetida, métricas, bootstrap
Features (estadísticos, FFT, BLS)	Hecho	`src/features.py`, `scripts/compute_features.py`
Baseline RF / XGBoost y ablación por familia	Hecho	`src/models_classic.py`, `05_baseline`
CNN 1D (versión inicial)	Hecho	`src/models_cnn.py`, `06_cnn`
Data augmentation y ajuste de la CNN	Pendiente	desplazamiento circular, inversión, ruido
Ajuste de hiperparámetros y umbral	Pendiente	validación anidada; umbral elegido en CV
Ablación completa	Pendiente	preprocesamiento, ponderación, augmentation
Interpretabilidad	Pendiente	saliencia, Grad-CAM 1D, análisis de errores
Sensibilidad a la cadencia y al BLS	Pendiente	variar cadencia y rango de períodos
Informe final, README y presentación	Pendiente	`report/`, `README.md`

4. Datos y preprocesamiento

Usamos *Kepler labelled time series data* (Kaggle, CC0): `exoTrain` con 5.087 estrellas (37 con planeta) y `exoTest` con 570 (5 con planeta), cada una con 3.197 mediciones de flujo. No hay valores faltantes. El dataset no trae marcas de tiempo: para el BLS suponemos una cadencia uniforme de 30 minutos (una curva de unos 66,6 días). Más del 99 % de los datos pertenece a una misma campaña y los positivos extra provienen de otras, lo que podría introducir diferencias ajenas al planeta (ver Sección 6).

En la exploración vimos que las escalas son muy heterogéneas (desviación estándar entre 1,7 y más de 10^6) y que las curvas crudas están dominadas por tendencias lentas que ocultan los tránsitos. El preprocesamiento, en `src/preprocessing.py`, tiene tres pasos por estrella:

1. **Detrending:** se resta una mediana móvil de 101 puntos (≈50 h). Probamos ventanas de 25, 101, 301 y 701 (Figura 3): con 701 queda tendencia sin quitar y 25 arriesga absorber tránsitos largos.
2. **Recorte de picos hacia arriba** a 4σ: un tránsito solo baja el brillo, así que los picos positivos son ruido; las caídas no se tocan.
3. **Normalización:** se resta la mediana y se divide por la desviación robusta ($1{,}4826 \cdot \mathrm{MAD}$).

Al revisar los resultados detectamos que en 4 estrellas sin planeta más del 58 % de los puntos queda exactamente en 0 tras el detrending, con MAD nulo y valores de hasta -10^{16} al normalizar; en esos casos se usa la desviación estándar común.

5. Primeros experimentos

Todas las cifras son PR-AUC, cuyo valor al azar es 0,007 (la proporción de positivos). Un modelo que siempre responde "sin planeta" obtiene 0,007 y una regresión logística sobre 3 features simples $0{,}073 \pm 0{,}068$. La mejor feature individual es el contraste del BLS (0,088).

Features	Random Forest	XGBoost
Estadísticos (8)	$0{,}045 \pm 0{,}046$	$0{,}030 \pm 0{,}018$
FFT (4)	$0{,}151 \pm 0{,}081$	$0{,}129 \pm 0{,}076$
BLS (6)	$0{,}347 \pm 0{,}159$	$0{,}305 \pm 0{,}161$
Todas (18)	$\mathbf{0{,}394 \pm 0{,}200}$	$\mathbf{0{,}374 \pm 0{,}181}$

Cuadro 1: PR-AUC (media ± desviación entre folds), CV 5×5, según las features usadas.

Lectura. (i) Las features físicas importan: pasar de estadísticos a BLS multiplica el PR-AUC por cerca de 8, y con todas se llega a unas 50 veces el azar. (ii) La FFT aporta poco: sumarla al BLS mejora de 0,35 a 0,39, menos que la variación entre folds. (iii) Random Forest y XGBoost rinden parecido.

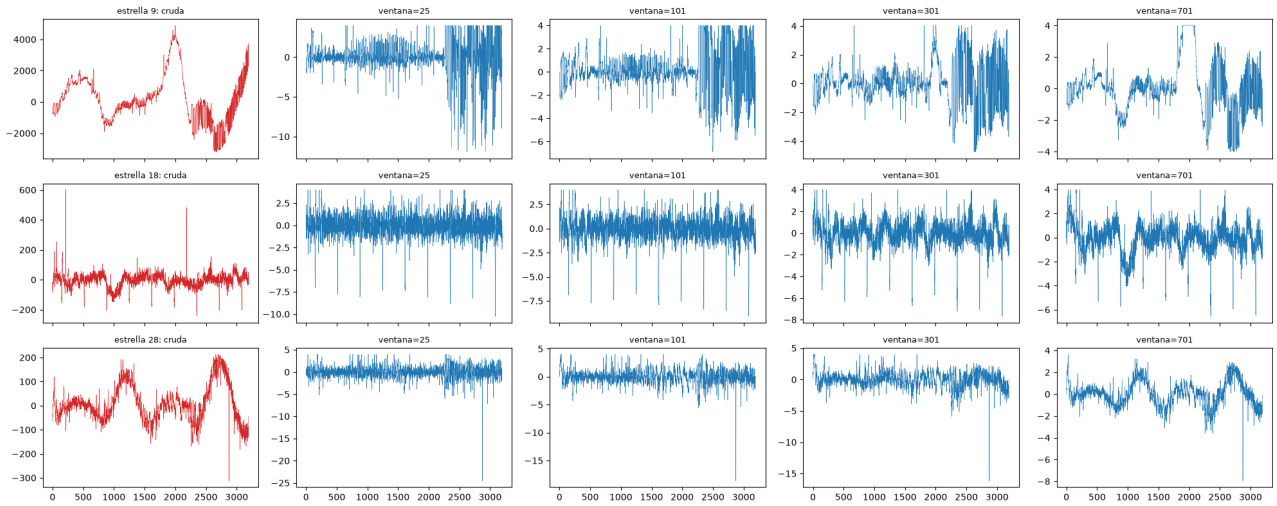


Figura 3: Tres estrellas con planeta: curva cruda (izquierda) y procesada con ventanas de 25, 101, 301 y 701 puntos. En la estrella 18 las caídas periódicas se ven con 25 y 101 y se pierden con 701.

	CV 5 folds × 1			**Test oficial (5 positivos)**		
Modelo	PR-AUC	Recall	Precisión	PR-AUC [IC 95 %]	Recall	Precisión
CNN 1D	$0{,}27 \pm 0{,}16$	0,56	0,20	0,56 [0,37; 1,00]	1,0	0,33
Random Forest	$0{,}42 \pm 0{,}18$	0,11	0,80	0,58 [0,16; 1,00]	0,4	1,0
XGBoost	$0{,}37 \pm 0{,}18$	0,36	0,37	0,67 [0,29; 1,00]	0,6	0,5

Cuadro 2: CNN 1D frente a los modelos con las 18 features, sobre los mismos folds. Recall y precisión con umbral 0,5, sin optimizar.

(iv) En CV la CNN rinde menos (0,27) pero es la que detecta más planetas (recall 0,56, con más falsas alarmas); en el test ubica los 5 planetas entre las posiciones 3 y 7 de 570. (v) Con 5 positivos los intervalos casi se solapan, así que no hay evidencia de que un modelo sea mejor; la CV (37 positivos) es la evidencia más confiable, y aun ahí la desviación entre folds (∼0,2) supera muchas diferencias entre modelos.

6. Riesgos y ajustes al plan

- **Muy pocos positivos** (37 y 5): resultados inestables. Se mitiga con CV repetida e intervalos bootstrap, y el test oficial solo confirma.
- **Posible sesgo por campaña:** los positivos extra vienen de otras campañas y el modelo podría separar por origen y no por planeta. No lo hemos verificado; se revisará con saliencia, Grad-CAM y análisis de errores.
- **Supuesto de cadencia** de 30 minutos: afecta período y duración del BLS. Se medirá la sensibilidad variando la cadencia y el rango de períodos.
- **CNN por debajo del baseline:** hipótesis (sin probar): el *global max pooling* detecta caídas pero no su repetición. Se probará *data augmentation*, un entrenamiento más estable (menor peso de clase, tasa decreciente) y una variante que combine la CNN con features BLS.
- **Caída aislada interpretada como período:** en la estrella 28 el BLS usa una sola caída; se agregarán features de consistencia entre tránsitos.
- **Hiperparámetros y umbral sin ajustar:** se hará búsqueda con validación anidada y se elegirá el umbral en CV, no en el test.
- **Cómputo:** el BLS tarda unos 6 min en las 5.657 estrellas (12 núcleos) y la CNN unos 7 min por 5 folds, por lo que una CV 5×5 de la CNN (≈35 min) es viable.

Calendario hasta el 20 de noviembre: semana 1, *augmentation* y mejora de la CNN; semana 2, ablación completa y ajuste de hiperparámetros; semana 3, interpretabilidad y sensibilidad a la cadencia; semana 4, informe final, README y presentación.

Referencias

[1] Megan Ansdell, Yani Ioannou, Hugh P. Osborn, Michele Sasdelli, et al. Scientific domain knowledge improves exoplanet transit classification with deep learning. *The Astrophysical Journal Letters*, 869(1):L7, 2018.

[2] Géza Kovács, Shay Zucker, and Tsevi Mazeh. A box-fitting algorithm in the search for periodic transits. *Astronomy & Astrophysics*, 391:369–377, 2002.

[3] Abhishek Malik, Benjamin P. Moster, and Christian Obermeier. Exoplanet detection using machine learning. *Monthly Notices of the Royal Astronomical Society*, 513(4):5505–5516, 2022.

[4] Ishaani Priyadarshini and Vikram Puri. A convolutional neural network (CNN) based ensemble model for exoplanet detection. *Earth Science Informatics*, 14:735–747, 2021.

[5] Ramprasaath R. Selvaraju, Michael Cogswell, Abhishek Das, Ramakrishna Vedantam, Devi Parikh, and Dhruv Batra. Grad-CAM: Visual explanations from deep networks via gradient-based localization. In *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*, pages 618–626, 2017.

[6] Christopher J. Shallue and Andrew Vanderburg. Identifying exoplanets with deep learning: A five-planet resonant chain around Kepler-80 and an eighth planet around Kepler-90. *The Astronomical Journal*, 155(2):94, 2018.