Detección de exoplanetas en curvas de luz de Kepler: features físicas versus redes convolucionales 1D

INF396 – Propuesta de proyecto

Noelia Morales Matías Lara
Ingeniería Civil Informática, Universidad Técnica Federico Santa María

1. Descripción del problema

Este trabajo trata sobre la **detección automática de estrellas con exoplanetas** a partir de sus **curvas de luz**, es decir, series de tiempo del flujo luminoso medido por el telescopio espacial Kepler. Cuando un planeta pasa frente a su estrella (*tránsito*), bloquea una pequeña fracción de su luz y produce una caída breve y periódica del flujo. Detectar esa señal es difícil: la caída suele ser muy pequeña comparada con el ruido instrumental y con la variabilidad propia de la estrella, y las estrellas con planetas confirmados son extremadamente escasas.

En la literatura, las redes convolucionales han mostrado ser efectivas para clasificar señales de tránsito en datos de Kepler [6, 1], y los clasificadores de *gradient boosting* sobre features extraídas de la curva alcanzan resultados comparables con un costo computacional mucho menor [3]. Sobre el mismo dataset que usaremos, Priyadarshini y Puri [4] reportan un 99,62 % de *accuracy* con un ensamble de CNN. Sin embargo, como solo el 0,9 % del conjunto de prueba es positivo, un clasificador que prediga "sin planeta" para todas las estrellas ya obtiene un 99,12 %. Esto muestra que la *accuracy* no sirve para evaluar el problema y motiva un protocolo de evaluación más riguroso.

2. Objetivo del trabajo

Nuestro objetivo es comparar un clasificador basado en features con significado físico contra una red neuronal convolucional 1D para detectar exoplanetas en curvas de luz de Kepler, con un protocolo de evaluación adecuado al fuerte desbalance de clases, y analizar mediante técnicas de interpretabilidad qué patrones aprende la red. En concreto:

1. **Baseline con features físicas:** además de estadísticos descriptivos, extraer features del espectro de Fourier (FFT) y del periodograma *Box Least Squares* (BLS) [2]: período, profundidad, duración y potencia del tránsito más probable. Entrenar sobre ellas Random Forest y XGBoost.
2. **Modelo secuencial:** entrenar una CNN 1D directamente sobre la curva preprocesada (*detrending* con filtro de mediana y normalización), manejando el desbalance con ponderación de clases y *data augmentation* propia de series de tiempo (desplazamientos circulares, inversión temporal, ruido gaussiano).
3. **Estudio de ablación:** medir el aporte de cada decisión de diseño (preprocesamiento, ponderación de clases, *augmentation*, tipo de features) activándolas una a la vez.
4. **Interpretabilidad:** aplicar mapas de saliencia y Grad-CAM 1D [5] para verificar si la CNN basa sus predicciones en los tránsitos o en artefactos, y analizar los falsos positivos y negativos.

Como métricas usaremos *recall*, precisión, F1 y el área bajo la curva precisión–*recall* (PR-AUC). Dado que el conjunto de prueba original tiene solo 5 positivos, las estimaremos con validación cruzada estratificada repetida e intervalos de confianza por *bootstrap*, además de reportarlas sobre el conjunto de prueba oficial.

3. Punto de partida

El proyecto no continúa un trabajo anterior. Existen implementaciones públicas relacionadas: el código de AstroNet [6], que trabaja con curvas ya plegadas en fase del catálogo DR24 y no con este dataset, y numerosos notebooks en Kaggle que entrenan CNN o SVM sobre este mismo conjunto. Estos últimos suelen reportar *accuracy* sobre un conjunto de prueba con 5 positivos y aplican técnicas como SMOTE

directamente sobre la serie cruda. Nuestro aporte está en: (i) usar features físicas (BLS/FFT) en lugar de estadísticos genéricos; (ii) un protocolo de evaluación robusto al desbalance; (iii) un estudio de ablación sistemático; y (iv) el análisis de interpretabilidad de la CNN.

4. Dataset

Usaremos *Exoplanet Hunting in Deep Space – Kepler labelled time series data*[1] (licencia CC0). Contiene curvas de luz ya limpiadas por NASA, con 3.197 mediciones de flujo por estrella y una etiqueta binaria (planeta confirmado o no). Más del 99 % de los datos proviene de la Campaña 3; para aumentar los positivos, se añadieron estrellas con planetas confirmados de otras campañas.

- `exoTrain.csv`: 5.087 estrellas, de las cuales 37 tienen exoplanetas (0,73 %).
- `exoTest.csv`: 570 estrellas, de las cuales 5 tienen exoplanetas (0,88 %).

El dataset no incluye marcas de tiempo. Para calcular el BLS supondremos una cadencia uniforme de aproximadamente 30 minutos (la cadencia larga de Kepler) y evaluaremos la sensibilidad de los resultados a ese supuesto.

5. Artículos relacionados

[1] Megan Ansdell, Yani Ioannou, Hugh P. Osborn, Michele Sasdelli, et al. Scientific domain knowledge improves exoplanet transit classification with deep learning. *The Astrophysical Journal Letters*, 869(1):L7, 2018.

[2] Géza Kovács, Shay Zucker, and Tsevi Mazeh. A box-fitting algorithm in the search for periodic transits. *Astronomy & Astrophysics*, 391:369–377, 2002.

[3] Abhishek Malik, Benjamin P. Moster, and Christian Obermeier. Exoplanet detection using machine learning. *Monthly Notices of the Royal Astronomical Society*, 513(4):5505–5516, 2022.

[4] Ishaani Priyadarshini and Vikram Puri. A convolutional neural network (CNN) based ensemble model for exoplanet detection. *Earth Science Informatics*, 14:735–747, 2021.

[5] Ramprasaath R. Selvaraju, Michael Cogswell, Abhishek Das, Ramakrishna Vedantam, Devi Parikh, and Dhruv Batra. Grad-CAM: Visual explanations from deep networks via gradient-based localization. In *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*, pages 618–626, 2017.

[6] Christopher J. Shallue and Andrew Vanderburg. Identifying exoplanets with deep learning: A five-planet resonant chain around Kepler-80 and an eighth planet around Kepler-90. *The Astronomical Journal*, 155(2):94, 2018.

[1] `https://www.kaggle.com/datasets/keplersmachines/kepler-labelled-time-series-data`